CONCEPTOS DE BASES DE DATOS

CLASE 7

Dispersión

- Con la implementación de archivos de índices y el uso de las estructuras de árboles balanceados vistas hasta el momento (B, B* y B+), se logra acceder a cualquier dato de un archivo en 3 o 4 accesos a almacenamiento secundario.

- Sin embargo, para ciertos casos se necesita un mecanismo de acceso a registros con una única lectura → DISPERSIÓN (HASH)

Dispersión

Definiciones

- Técnica para generar una dirección base única para una clave dada
- Técnica que convierte la clave del registro en un número aleatorio, el que sirve después para determinar donde se almacena el registro
- Técnica de almacenamiento y recuperación que usa una función de hash para mapear registros en direcciones de almacenamiento

Dispersión

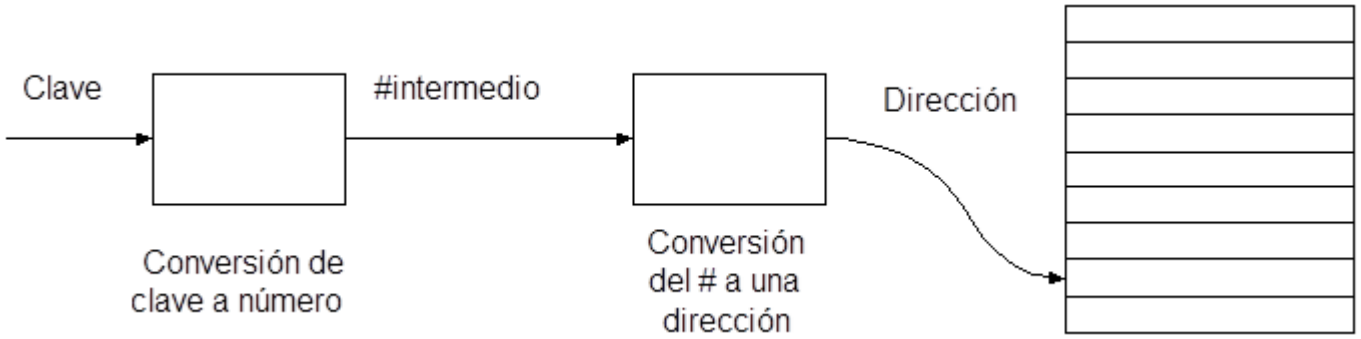

- Para determinar la dirección de un registro:
  - La clave se convierte en un número aleatorio
  - El número se convierte en una dirección de memoria
  - El registro se debe guardar en esa dirección
    - Si la dirección está completa: saturación (overflow) → **tratamiento especial**

Dispersión

- Beneficios
  - No requiere almacenamiento adicional (índices)
  - Facilita inserción y eliminación rápida de registros
  - Encuentra registros con muy pocos accesos al disco en promedio (generalmente menos de 2)
- Costos
  - No es posible el uso de registros de longitud variable
  - No existe el orden físico de datos
  - No permite claves duplicadas

Dispersión

- Algoritmos de dispersión
  - Uniforme: reparte los registros en forma uniforme en el espacio de direcciones disponible → difícil de lograr
  - Aleatoria: las claves son independientes, no influyen una sobre la otra. Cualquier dirección tiene la misma probabilidad de ser elegida para una clave

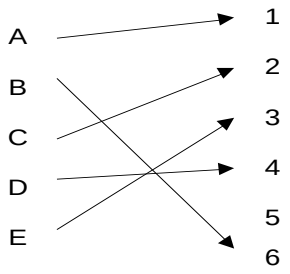

uniforme

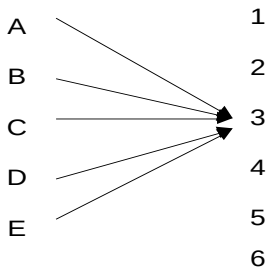

peor

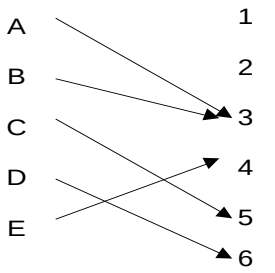

aceptable

Dispersión

- Tipos de dispersión
  - Con espacio de direccionamiento estático
    - El espacio disponible para dispersar los registros esta prefijado
  - Con espacio de direccionamiento dinámico
    - El espacio disponible para dispersar los registros aumenta o disminuye según las necesidades de espacio que en cada momento tiene el archivo

Dispersión

Estático

- Parámetros que afectan la eficiencia
  - Función de dispersión
  - Tamaño de los compartimentos (espacio de almacenamiento)
  - Densidad de empaquetamiento
  - Método de tratamiento de saturación

Dispersión

Estático

- Función de dispersión
  - **Caja negra**: a partir de una clave se obtiene la dirección donde debe estar el registro
  - **Diferencias con índices**
    - No hay relación aparente entre la clave y la dirección
    - Dos claves distintas pueden transformarse en una misma dirección → **colisión**
  - **Resultado**: retorna un valor aleatorio, que luego debe ser mapeado al rango de valores disponibles
  - **Ejemplo:** función simple usando códigos ASCII

Dispersión

Estático

- Función de dispersión → ejemplos
  - **Centros cuadrados**: la clave se multiplica por si misma y se toma los dígitos centrales, posteriormente se ajusta al espacio diponible.
  - **División**: la clave se divide por un nro aproximadamente igual a la cantidad de direcciones (número primo → tiende a distribuir residuos en forma más eficiente). Luego se obtiene el residuo.
  - **Desplazamiento**: se realiza un desplazamiento del número, se particiona y se suman las partes resultantes. Luego se ajusta al espacio disponible.
  - **Plegado**: se realiza el plegado del número, se suman las partes resultantes y adaptan al espacio de direcciones.
  - **Transformación de base**: la base del número se modifica y luego se toma el resultado del módulo.

Dispersión

Estático

- Función de dispersión → Centros cuadrados
  - **N= 7000 (direcciones)**
  - **Clave: 6 dígitos**

Clave = 172148

Clave ^ 2 = 029634933904 → 3493 * 0.7 = 2445

Para llevar al espacio asignado al archivo multiplico por 0.7, haciendo el calculo con la mayor clave posible: 7000/9999 = 0.7

Dispersión

Estático

- Función de dispersión → División
  - **N= 7000 (direcciones)**
  - **Clave: 6 dígitos**

Clave = 172148

Clave mod 6997 = 4220 → El resultado siempre estará entre 0 y 6996.

Dispersión

Estático

- Función de dispersión → Desplazamiento
  - **N= 7000 (direcciones)**
  - **Clave: 8 dígitos**

Clave = 20175973

Clave desplazada= 17207359 = 1720 + 7359 → 9079 * 0.35 = 3177

Para llevar al espacio asignado al archivo multiplico por 0.35, haciendo el calculo con la mayor clave posible: 7000/19998 = 0.35

Dispersión

Estático

- Función de dispersión → Plegado
  - **N= 999 (direcciones)**
  - **Clave: 8 dígitos**

Clave = 17207359

Clave plegada en 3 partes = 017 207 359 = 953 + 207 + 710 → 1870 * 0.33 = 617

Para llevar al espacio asignado al archivo multiplico por 0.33, haciendo el calculo con la mayor clave posible: 999/2988 = 0.33

Dispersión

Estático

- Función de dispersión → Transformación de base
  - **N= 100 (direcciones)**
  - **Clave: 3 dígitos**

Clave = 453

Clave en base 11 = 382 → 382 * 0.12 = 45

Para llevar al espacio asignado al archivo multiplico por 0.12, haciendo el calculo con la mayor clave posible: 100/829 = 0.12

Dispersión

Estático

- Función de dispersión
  - ¿Cuál elegir?
  - Tomar algunas claves del problema y simular el comportamiento con algunos métodos, y luego elegir el que **mejor** se comporte
  - En general:
    - División mejor
    - Plegado, para claves muy largas

Dispersión

Estático

- Colisiones
  - Cuando un registro es asignado a una dirección ya ocupada, se produce una colisión
    - A las claves que por dispersión se convierten en la misma dirección se las llama sinónimos
  - No existe un algoritmo de dispersión perfecto, que no genere colisiones
  - Alternativa → minimizar las colisiones

Dispersión

Estático

- Colisiones → disminución
  - **Esparcir registros**: buscar métodos que distribuyan los registros de la forma más aleatoria posible entre las direcciones disponibles
    - Suma de códigos ASCII → no es bueno
    - Las otras funciones vistas → elegir la mejor para cada caso particular
  - **Usar memoria adicional**: distribuir pocos registros en muchas direcciones (ej: 75 registros en 1000 direcciones)
    - Disminuye las colisiones
    - Desperdicia espacio

Dispersión

Estático

- Colisiones → disminución
  - **Colocar más de un registro por dirección**
    - Direcciones con **N** claves → mejoras notables
    - Las direcciones que pueden almacenar 1 o más registros se denominan **cubetas** o **compartimentos**
    - **Ejemplo**: archivo con direcciones de **512** bytes y cada registro a almacenar tiene un tamaño de **80** bytes
      - Se puede almacenar hasta 6 registros por cada dirección asignada al archivo (cada dirección tolera **hasta 5 sinónimos**)

Dispersión

Estático

- Tamaño de los compartimentos
  - A **mayor tamaño** del compartimento:
    - Menor probabilidad de saturación
    - Mayor fragmentación → espacios vacíos
    - Búsqueda más lenta dentro del compartimento

Dispersión

Estático

- Tamaño de los compartimentos
  - ¿Cuál es el tamaño adecuado del compartimento?
    - **Depende del sistema**: el tamaño máximo dependerá de las posibilidades de transferencia en operaciones de E/S → buffers SO
    - **Tamaño muy grande** → la recuperación de un registro es muy lenta

Dispersión

Estático

- Densidad de empaquetamiento (DE)
  - No es relevante el tamaño total del archivo. La DE es la proporción de espacio asignado al archivo que **en realidad almacena registros**
    - Cantidad de espacio que es usado en un archivo
  - $DE = \frac{\text{número de registros del archivo}}{\text{capacidad total de las cubetas}}$
  - Si se cuenta con una DE menor:
    - Menor saturación
    - Mayor desperdicio de espacio

Dispersión

Estimación overflow

- Es posible realizar una estimación de la saturación analizando las características de su almacenamiento
  - **N**= #cubetas, **C**= capacidad cubeta, **K**= #reg. del archivo

$$DE = \frac{K}{C \times N}$$

  - ¿Cuál es la probabilidad de que una cubeta en particular reciba una cantidad determinada de registros?

Dispersión

Estimación overflow

- Estimación del Nº de claves que recibe una cubeta
  - **Dadas:**
    - **A** = no utilizar una cubeta en particular
    - **B** = utilizar una cubeta en particular
  - Para **una clave**:
    P(B) = 1/N **P(A) = 1 – P(B) = 1 – 1/N**
  - Para **dos claves**:
    P(BB) = P(B) * P(B) = $(1/N)^2$
    P(BA) = P(B) * P(A) = (1/N) * (1 – 1/N)

    (cada clave es independiente, función de hash uniforme)

Dispersión

Estimación overflow

- Estimación del Nº de claves que recibe una cubeta
  - **P(secuencia) = P(A)$^{\#A}$ * P(B)$^{\#B}$**
  - Para una secuencia determinada de **K** claves, la probabilidad de que **I** caigan en una cubeta es:

$$(1/N)^I * (1 - 1/N)^{K-I}$$

  - La cantidad de formas de **combinar** esa secuencia es (**K** tomadas de a **I** combinaciones):

$$\frac{K!}{I!*(K-I)!}$$

Dispersión

Estimación overflow

- Estimación del Nº de claves que recibe una cubeta
  - La probabilidad de que una cubeta reciba **I** elementos de los **K** disponibles es entonces:

$$P(I) = \underbrace{\frac{K!}{I!*(K-I)!}}_{\text{COMBINATORIO } \binom{K}{I}} * \underbrace{(\frac{1}{N})^I * (1-\frac{1}{N})^{K-I}}_{\substack{P(B) \\ I \text{ VECES}} * \substack{P(A) \\ K-I \text{ VECES}}}$$

  - Fórmula equivalente acotada:

$$P(I) = \frac{(K/N)^I * e^{-(K/N)}}{I!}$$

Dispersión

Estimación overflow

- En general, si hay **N** direcciones → el nro esperado de direcciones con **I** registros asignados es igual a **N***P(**I**)
- Se analizarán archivos con diferentes DE, estimando la saturación en cada caso
- Ejemplo 1: **N** = **10000** **K** = **10000** **DE** = **1** → 100%
  - La proporción de direcciones con 0 registros asignados es:

$$P(0) = \frac{(10.000 / 10.000)^0 * e^{-(10.000/10.000)}}{0!} = 0.3679$$

Dispersión

Estimación overflow

- Ejemplo 1: **N** = **10000** **K** = **10000** **DE** = **1**
  - Nº de direcciones **sin registros** asignados (**I** = **0**):

0: 10000 * P(0) = 10000 * 0.3679 = **3679**

  - Nº de direcciones **con uno, dos y tres registros**:

1: 10000 * P(1) = 10000 * 0.3679 = **3679**
2: 10000 * P(2) = 10000 * 0.1839 = **1839**
3: 10000 * P(3) = 10000 * 0.0613 = **613**

Dispersión

Estimación overflow

- Ejemplo 1: **N = 10000** **K = 10000** **DE = 1**
  - La cantidad de registros en colisión será entonces:
    - 3679 direcciones tienen 0 registros asignados → **0**
    - 3679 direcciones tienen 1 registro asignado → **0**
    - 1839 direcciones tienen 2 registros asignados → **1839**
    - 613 direcciones tienen 3 registros asignados → **(613 * 2)**
  - Saturación estimada hasta el momento: **1839** + (**613*2**) = **3065**
    - Aún no se finalizó la estimación y ya es mayor a un 30%
    - Más del 30% de los registros serán almacenados en algún lugar que no es su dirección base

Dispersión

Estimación overflow

- Ejemplo 2: **N** = **1000** **K** = **500** **DE** = **0.5**
  - Nº de direcciones **sin registros** asignados (**I** = **0**):

0: 1000 * P(0) = 1000 * 0. 607 = **607**

  - Nº de direcciones **con un sólo registro**:

1: 1000 * P(1) = 1000 * 0.303 = **303**

  - Nº de direcciones **con más de un registro**:

2: 1000 * P(2) = 1000 * 0.0758 = **75**
3: 1000 * P(3) = 1000 * 0.0126 = **12**
4: 1000 * P(4) = 1000 * 0.0016 = **1**
5: 1000 * P(5) = 1000 * 0.0002 = **0**

Dispersión

Estimación overflow

- Ejemplo 2: **N** = **1000** **K** = **500** **DE** = **0.5**
  - ¿Cuántos registros en saturación pueden esperarse?

→ **N** * (1* P(2) + 2* P(3) + 3 * P(4) + 4 * P(5)) =

= 1000 * (1* 0.0758 + 2* 0.0126 + 3*0.0016 + 4*0.0002) =

= **107**

  - Dado que se cuenta con 500 registros en total, la saturación estimada hasta el momento es: **107/500** = **0.214** = **21.4 %**
    - Más del **21%** de los registros serán almacenados en algún lugar que no es su dirección base

Dispersión

Estimación overflow

- Valores de saturación para diferentes DE

DE	Saturación	
0.10	4.8 %	
0.30	13.6 %	
0.50	21.4 %	→ Ejemplo 2
0.70	28.1 %	
0.80	31.2 %	
0.90	34.1 %	
1.00	36.8 %	→ Ejemplo 1

Dispersión

Estimación overflow

- En los ejemplos se utilizó compartimentos con capacidad para un único registro
  - En estos casos, los términos de colisión y saturación son **equivalentes**
- Los números bajos de saturación se presentan cuando se dispone de una baja DE
  - Disminuye la cantidad de colisiones
  - Deja muchas direcciones (compartimentos) libres
- Solución → usar compartimentos con capacidad para más de un registro

Dispersión

Estimación overflow

- Si se consideran compartimentos con capacidad para más de un registro:
  - Dependiendo de su **capacidad** y del **lugar libre** que tenga un compartimento en un momento dado, dos sinónimos se podrán almacenar en la misma dirección
  - Entonces ahora, al producirse una colisión:
    - Si el compartimento **tiene lugar suficiente** el registro se almacena en dicho lugar → **no hay saturación**
    - Si el compartimento **está completo** (no tiene más lugar) entonces si **se produce saturación**

Dispersión

Estimación overflow

K: Nº registros **B**: Tamaño de compartimento
N: Nº de direcciones de memoria disponibles

DE = **K** / **B** * **N**

	Archivo 1	Archivo 2
Nº registros (K)	750	750
Nº direcciones (N)	1000	500
Tamaño Comp. (B)	1	2
DE	0.75	0.75
Proporción regs/dirs	0.75	1.5

Dispersión

Estimación overflow

- Con 750 registros, 1000 direcciones de memoria disponibles y compartimentos de tamaño 1, el Nº esperado de registros en saturación es:

→ **N** * (1* P(2) + 2* P(3) + 3 * P(4) + 4 * P(5)) =

= 1000 * (1*0.1328 + 2*0.0332+ 3*0.0062+ 4*0.0009+5*0.0001)

= **222**

- **Saturación = 222/ 750 = 29.6 %**

Dispersión

Estimación overflow

- Con 750 registros, 500 direcciones de memoria disponibles y compartimentos de tamaño 2, el Nº esperado de registros en saturación es:

→ **N** * (1*P(3) + 2*P(4) + 3*P(5) + 4*P(6) + 5*P(7)) =

= 500 * (1*0.1255 + 2*0.0471+ 3*0.0141+ 4*0.0035+5*0.0008) = 140

= **140**

- **Saturación = 140/ 750 = 18.7 %** → mejora

Dispersión

Estimación overflow

- Probabilidad de saturación

	TAMAÑO COMPARTIMENTO				
DE	1	2	5	10	100
10%	4.8	0.6	0.0	0.0	0.0
20 %	9.4	2.2	0.1	0.0	0.0
30 %	13.6	4.5	0.4	0.0	0.0
40 %	17.6	7.3	1.1	0.1	0.0
50 %	21.4	10.4	2.5	0.4	0.0
60 %	24.8	13.7	4.5	1.3	0.0
70 %	28.1	17.0	7.1	2.9	0.0
75 %	29.6	18.7	8.6	4.0	0.0
80 %	31.2	20.4	10.3	5.3	0.1
90 %	34.1	23.8	13.8	8.9	0.8
100 %	36.8	27.1	17.6	12.5	4.0